مقدمه

در این گزارش به‌صورت جامع پیاده‌سازی، آزمایش‌ها و تحلیل‌های مربوط به پروژه فاز اول هوش‌مصنوعی — رگرسیون خطی تک‌متغیره برای پیش‌بینی مقدار Attack بر اساس ویژگی — Defense آورده شده است.

بخش 1 — شرح مسئله و اهداف کلی

سوال: مسئله چیست و چه اهدافی داریم؟

پاسخ: مسئله مدل‌سازی رابطه بین یک ویژگی (Defense) و خروجی (Attack) با یک خط ساده است (یعنی رگرسیون خطی یک‌متغیره). هدف اصلی یافتن پارامترهای مدل (عرض از مبدا و شیب) به‌طوری که خطای پیش‌بینی (معیار MSE) کمینه شود. اهداف فرعی شامل مقایسه روش‌های یافتن پارامتر (جستجوی شبکه‌ای و گرادیان‌نزولی)، اندازه‌گیری اثر نرمال‌سازی روی رفتار آموزش، و تحلیل نتایج است.

سوال: چرا این مسئله انتخاب شده؟

پاسخ: این مسئله ساده اما آموزنده است؛ هم ریاضی پایه‌ای رگرسیون را نشان می‌دهد و هم به خوبی اجازه می‌دهد تأثیر پیش‌پردازش (نرمال‌سازی) و انتخاب هایپرپارامترها روی همگرایی گرادیان‌نزولی را بررسی کنیم. فایل پروژه هم همین تمرکز را پیشنهاد می‌کند و خواسته که با داده‌های پوکمون (ستون Defense و Attack) کار کنیم.

بخش 2 — داده‌ها و پیش‌پردازش

سوال: داده‌ها چه هستند؟ چند نمونه استفاده شده و چرا؟

پاسخ: داده‌ها از مجموعه پوکمون‌ها هستند و فقط ستون‌های Defense (ورودی) و Attack (خروجی) انتخاب شده‌اند. مطابق شرح پروژه، در پیاده‌سازی برای سادگی ابتدا ۱۰ نمونه اول (مرتب‌شده بر اساس Defense) استفاده شد تا رفتار اولیه مدل و الگوریتم‌ها دیده شود. اندازه کوچک نمونه برای تمرین و نشان دادن رفتار الگوریتم کافیست ولی برای نتیجه‌گیری کلی باید کل داده استفاده شود.

سوال: چه پیش‌پردازش‌هایی انجام شده؟

پاسخ: دو حالت بررسی شد:

1. حالت بدون پیش‌پردازش (داده خام.(
2. حالت با نرمال‌سازی استاندارد فقط برای ویژگی) Defense میانگین صفر و انحراف معیار یک) و نگه‌داشتن Attack در مقیاس اصلی تاMSE ها قابل مقایسه باشند. نرمال‌سازی برای پایدار کردن گرادیان‌نزولی و اجازه دادن به نرخ یادگیری بزرگ‌تر ضروری بود. (روش استاندارد برابر $x' = (x - \mu) / \sigma$).

تحلیل کوتاه داده/پیش‌پردازش:

- استفاده از ۱۰ نمونه باعث می‌شود نویز نمونه‌ای بیشتر دیده شود؛ به همین دلیل نتایج باید با احتیاط تفسیر شوند.
- نرمال‌سازی روی x (Defense) بیشترین تأثیر را روی همگرایی گرادیان‌نزولی داشت، چون مقیاس x روی مشتقات w1 تاثیر مستقیم دارد.

بخش 3 — مدل و معیار ارزیابی

سوال: مدل دقیقاً چیست و با چه معیاری سنجیده می‌شود؟

پاسخ (بدون فرمول سنگین):

مدل، یک خط ساده است که به ازای هر مقدار Defense یک مقدار Attack پیش‌بینی می‌کند (خط: عرض از مبدأ + ضریب .(Defense × معیار کیفیت مدل میانگین مربعات خطا (MSE) است؛ یعنی میانگین مربع اختلاف بین مقادیر واقعی Attack و مقادیر پیش‌بینی‌شده. هدف کمینه کردن این مقدار است.

سوال: چرا MSE انتخاب شده؟

پاسخ MSE :رایج و ساده است، حساس به خطاهای بزرگ است (خطاهای بزرگ را سنگین‌تر می‌کند) و مشتق‌پذیر است که برای روش‌های مشتق‌محور مثل گرادیان‌نزولی مناسب است.

بخش 4 — روش‌ها (هر روش با «سوال» و پاسخ(

۴.۱ — Grid Search

سوال Grid Search :چیست و چرا از آن استفاده شده؟

پاسخ: در Grid Search یک بازه یا تعدادی مقدار ممکن برای پارامترها تعیین می‌شود و مدل برای هر ترکیب این پارامترها ارزیابی می‌شود تا بهترین ترکیب از نظر MSE انتخاب شود. این روش ساده و مطمئن است ولی اگر فضای پارامتر بزرگ یا بردار پارامترها بزرگ باشد، بسیار هزینه‌بر می‌شود. در این پروژه از Grid Search به‌عنوان راه سریع برای یافتن یک تقریبی از پارامترها و درک شکل کلی تابع هزینه استفاده شده است.

نتیجه عملی (از پیاده‌سازی:(

- در شبکه آزمایشی محدود (مثلاً w0 ثابت و چند مقدار ،(w1 بهترین مقدار اولیه‌ای که یافت شد حدود (w0=0) w1=1بود و MSE حدود 221.5 گزارش شد (این یک تقریب خام است؛ شبکه گسترده‌تر ممکن است بهتر پیدا کند.(

تحلیل:

- Grid Searchدید خوبی از رفتار تابع هزینه می‌دهد اما برای تخمین دقیق پارامترها روی داده واقعی یا فضای بزرگ مناسب نیست؛ به‌خصوص اگر بخواهیم پارامترها را دقیق‌تر یا به‌صورت خودکار پیدا کنیم.

) Gradient Descent — ۴.۲گرادیان‌نزولی)

سوال: گرادیان‌نزولی چه کاری انجام می‌دهد و چه پارامترهایی مهم‌اند؟

پاسخ:

گرادیان‌نزولی از شیب تابع خطا استفاده می‌کند تا پارامترها را به‌صورت تکراری به سمت کاهش خطا حرکت دهد. پارامترهای مهم شامل نرخ یادگیری ،(alpha) تعداد تکرارها ،(iterations) شرط توقف (مثل تغییرات کوچک در MSE یا حداکثر تکرار)، و مقادیر اولیه وزن‌ها هستند. نرخ یادگیری خیلی بزرگ ← واگرایی، خیلی کوچک ← همگرایی خیلی کند. فایل پروژه به این حساسیت‌ها اشاره کرده و پیشنهاد کرده مقادیر مختلف alpha آزمایش شود.

نتایج کلیدی از پیاده‌سازی:

- روی داده خامalpha :های بزرگ (مثلاً 0.1) باعث ناپایداری یا NaN در وزن‌ها شدند alpha ؛خیلی کوچک (مثلاً 0.0001) همگرایی داشت اما بسیار کند بود (نیاز به هزاران تکرار.(

- با نرمال‌سازی :x امکان انتخاب alpha بزرگ‌تر (مثلاً 0.1) شد؛ الگوریتم سریع‌تر همگرا شد (حدود 50–60 تکرار) و MSE نهایی کاهش یافت (مثلاً ~155.48) که بهتر از نتیجه Grid Search بود.

تحلیل:

- نتیجه نشان داد که گرادیان‌نزولی با تنظیم مناسب نرخ یادگیری و پیش‌پردازش مناسب می‌تواند نتیجه‌ای بهتر و سریع‌تر نسبت به جستجوی شبکه‌ای محدود به‌دست دهد.

— ۴.۳سوالات مربوط به مشتق/روش به‌صورت عمومی

سوال: مشتق تابع هزینه نسبت به پارامترها چرا لازم است؟

پاسخ: مشتق جهت و بزرگیِ تغییر پارامترها را نشان می‌دهد؛ گرادیان‌نزولی از آن برای تشخیص اینکه پارامترها را در چه جهتی و به چه اندازه تغییر دهد استفاده می‌کند.

بخش 5 — نرمال‌سازی و تأثیر آن

سوال: نرمال‌سازی چرا ضروری است و چگونه انجام شده؟

پاسخ: وقتی مقادیر ورودی (Defense) در مقیاس بزرگ یا متفاوتی نسبت به سایر کمیت‌ها باشند، مشتقات نسبت به یک پارامتر (w1) می‌تواند بسیار بزرگ شود و باعث شود برای ثابت نگه داشتن پایدار الگوریتم، نرخ یادگیری بسیار کوچک انتخاب شود (که کندی را به همراه دارد) یا اگر نرخ یادگیری بزرگ انتخاب شود الگوریتم واگرا شود. با استانداردسازی (کاهش میانگین به صفر و تنظیم واریانس به ۱) رفتار تابع هزینه نرم‌تر و شرایط همگرایی مناسب‌تر می‌شود. در این پروژه استانداردسازی تنها روی x (Defense) انجام شد تا مقایسه MSE در مقیاس اصلی خروجی راحت باشد.

نتیجه عملی و تحلیل:

- بدون نرمال‌سازی: گرادیان‌نزولی یا واگرا شد (alpha بزرگ) یا کند همگرا شد (alpha کوچک.)
- با نرمال‌سازی: امکان استفاده از alpha=0.1 شد؛ همگرایی در ~50 تکرار و MSE نهایی کاهش یافت (~155). این به وضوح نشان می‌دهد نرمال‌سازی سرعت و پایداری آموزش را بهبود می‌بخشد.

بخش 6 — تنظیم هایپرپارامترها و پیشنهادات عملی

سوال: چه هایپرپارامترهایی را باید تنظیم کنیم و چه بازه‌هایی پیشنهاد می‌شود؟

پاسخ: هایپرپارامترهای کلیدی: نرخ یادگیری ،(alpha) تعداد تکرارها ،(iterations) شرط توقف ،(epsilon)مقدار اولیه وزن‌ها، و اندازه شبکه در .Grid Search پیشنهادهای تجربی (بر اساس فایل پروژه و اجرای نوت‌بوک): تست alpha در مجموعه‌ای شبیه {0.5, 0.1, 0.01, 0.001, 0.0001}؛ برای هر alpha پیگیری تغییر MSE در هر تکرار تا ببینیم آیا واگرایی یا همگرایی داریم. برای شرط توقف می‌توان از تغییر MSEکمتر از یک آستانه کوچک یا حداکثر تعداد تکرار (مثلاً 10k) استفاده کرد..

بخش 7 — پیاده‌سازی (خلاصه مراحل عملی و نکات کد:(

1. خواندن CSV، انتخاب ستون Defense و Attack و انتخاب ۱۰ نمونه اول برای آزمایش اولیه.
2. تابع محاسبه MSE نوشتن (خروجی: عدد.(
3. پیاده‌سازی :Grid Search تکرار روی مقادیر مشخص) w1 و گاه (w0 و محاسبه MSE برای هر ترکیب.
4. پیاده‌سازی گرادیان‌نزولی: حلقه تکراری که در هر تکرار مشتقات را محاسبه و وزن‌ها را آپدیت می‌کند. شرط توقف: تغییر کوچک MSE یا رسیدن به حداکثر تکرار.
5. اجرای آزمایش‌ها در دو حالت: داده خام و داده نرمال‌شده، ثبت تاریخچه MSE برای رسم منحنی همگرایی.

نکات مهم کدی: مقداردهی اولیه وزن‌ها (معمولاً صفر یا خیلی کوچک)، پایش NaN/inf در وزن‌ها، ذخیره و رسم منحنی MSE برای تشخیص واگرایی. (جزئیات کامل کد در AI_Phase1.ipynb موجود است.(

بخش 8 — نتایج تفصیلی و تحلیل هر بخش (خلاصه عددی و تفسیر(

۸.۱ نتایج Grid Search

- بهترین مقدار روی شبکه کوچکی که بررسی شد. $w0 \approx 0, w1 \approx 1 \rightarrow MSE \approx 221.50$:
  تحلیل: شبکه محدود بوده؛ بنابراین عدد به‌دست‌آمده یک تخمین اولیه است نه پاسخ نهایی.

۸.۲ نتایج گرادیان‌نزولی روی داده خام

- alpha بزرگ → واگرایی یا NaN.
- alpha خیلی کوچک → همگرایی بسیار کند (نیاز به هزارها تکرار).
  تحلیل: رفتار استاندارد زمانی که ورودی‌ها هم‌مقیاس نباشند.

۸.۳ نتایج گرادیان‌نزولی با نرمال‌سازی

- با استانداردسازی Defense و alpha مناسب (مثلاً 0.1 در اجرای من) همگرایی سریع رخ داد (حدود 50–60 تکرار) و MSE نهایی تقریباً 155.48 شد.
  تحلیل: کاهش قابل توجه MSE نسبت به Grid Search اولیه نشان می‌دهد گرادیان‌نزولی + نرمال‌سازی در این مجموعه نمونه بهتر عمل کرده است.

۸.۴ مقایسه روش‌ها

- سرعت و کیفیت: گرادیان‌نزولی (با نرمال‌سازی) بهتر و سریع‌تر از Grid Search محدود عمل کرد.
- هزینه محاسباتی Grid Search :در فضای بزرگ پرهزینه است؛ گرادیان‌نزولی مقیاس‌پذیرتر است اما نیاز به تنظیم هایپرپارامتر دارد.

بخش 9 — پاسخ سؤال‌های تکمیلی که در فایل پروژه مطرح شده‌اند(

سوال (بخش» :(«Grid Search» چرا Grid Search انجام دهیم و چه محدودیت‌هایی دارد؟»
پاسخ: برای دیدن شکل کلی تابع هزینه و یافتن یک تقریب اولیه خوب؛ اما محدودیت‌ها شامل پوشش ناکافی فضای پارامترها و هزینه محاسباتی بالا در شبکه‌های ریز یا فضای چندبعدی است.

سوال (بخش» :(«Gradient Descent» چه خطراتی برای انتخاب alpha وجود دارد و چطور متوجه واگرایی می‌شویم؟»

پاسخ alpha :خیلی بزرگ ← پارامترها نوسان یا انفجار پیدا می‌کنند (مقادیر بزرگ alpha .(NaN/خیلی کوچک ← همگرایی خیلی کند. واگرایی را با مشاهده افزایش متوالی یا ناپدید شدن (NaN/inf) در MSE یا وزن‌ها تشخیص می‌دهیم؛ بنابراین باید منحنی MSE را هر چند تکرار پایش کنیم.

سوال (بخش» :(«Normalization» آیا نرمال‌سازی فقط برای x کافی است یا y هم باید نرمال شود؟»
پاسخ: برای پایدارسازی همگرایی گرادیان‌نزولی نرمال‌سازی x کافی و موثر است. نرمال‌سازی y گاهی برای راحتیِ آموزش مفید است (وقتی شبکه/معماری پیچیده‌تر است) ولی چون ما معیار MSE را در مقیاس اصلی می‌خواهیم گزارش کنیم y ،را در این پروژه بدون تغییر نگه داشتیم.

سوال (بخش» :(«Hyperparameter» چطور مقادیر اولیه α و تعداد تکرار را انتخاب کنیم؟»
پاسخ: پیشنهاد تست چند مقدار log-scale برای) alpha مثلاً 0.5 تا 0.0001) و مشاهده منحنی .MSE تعداد تکرار باید تا وقتی MSE تغییر کمی می‌کند یا شرط حداکثر تکرار برسد، ادامه یابد. در عمل پس از نرمال‌سازی معمولاً alpha بین 0.01 و 0.1 مناسب است و تعداد تکرار چند ده تا چند صد کافی است (بسته به همگرایی..(

بخش 10 — محدودیت‌ها، خطاهای احتمالی و پیشنهادهای بهبود
محدودیت‌ها و خطاهای احتمالی:

- نمونه کوچک (۱۰ نمونه) ← قدرت تعمیم پایین.
- Grid Searchمحدود ← ممکن است مینیمم واقعی را پیدا نکند.
- احتمال خطا در مقادیر NaN/inf در صورت alpha نامناسب.
- نمایش ضرایب در حالت نرمال‌شده می‌تواند گیج‌کننده باشد — برای تفسیر وزن‌ها باید معکوس نرمال‌سازی را در نظر گرفت.

جمع‌بندی نهایی
در این پروژه ساده‌سازی‌شده، نشان داده شد که برای رگرسیون خطی تک‌متغیره پیش‌پردازشِ مناسب (نرمال‌سازی) و انتخاب هوشمندانهٔ هایپرپارامترها می‌تواند تفاوت زیادی در سرعت و کیفیت همگرایی ایجاد کند. جستجوی شبکه‌ای ابزار مفیدی برای دید کلی است، اما گرادیان‌نزولی (با نرمال‌سازی و alpha مناسب) عملکرد بهتری در

این اجرا نشان داد MSE) نهایی کاهش قابل‌توجهی داشت). برای نتایج قطعی‌تر باید از کل دیتاست و روش‌های اعتبارسنجی استفاده شود.